

# Relatório de Previsão de Séries Temporais

Victor Carreira

**Resumo**—Este relatório apresenta o resultado da previsão realizada por uma rede neural artificial *Multi Layer Perceptron* do tipo *Back Propagation* em um banco de dados da concessionária de energia elétrica, Light, com o intuito de se fazer a previsão mensal da sensação térmica das diversas regiões ou unidades geográficas que fazem parte da sua área de abrangência.

## I. INTRODUÇÃO

As Redes Neurais Artificiais (RNA) são inspiradas em modelos sensoriais do processamento de tarefas realizadas pelo cérebro (Hagan et al., 1996). Uma RNA, portanto pode ser criada através da aplicação de algoritmos matemáticos que imitem a tarefa realizada por um neurônio (Nedjah et al., 2016). Uma rede neural artificial possui semelhanças com a rede biológica presente no sistema nervoso central, neste o cômputo de informações realizado do cérebro é feito através de uma vasta quantidade de neurônios interconectados (Feldman et al., 1988; Poulton, 2002). A comunicação entre essas células é realizada através de impulsos elétricos. Estes são transmitidos e recebidos por meio de sinapses nervosas entre axônios e dendritos. As sinapses são estruturas elementares e uma unidade funcional localizada entre dois neurônios (Krogh, 2008).

McCulloch and Pitts (1943) redigem o trabalho pioneiro onde foi modelado um neurônio cuja resposta dependia do *input*<sup>1</sup> que provinha de outros neurônios e do peso utilizado. Já Rosenblatt (1962) cria a teoria de convergência do *Perceptron* onde ele prova que modelos de neurônios possuem propriedades similares ao cérebro humano (Kanal, 2001). Neste sentido as rede neuronais artificiais podem realizar performances sofisticadas no reconhecimento de padrões, mesmo se alguns neurônios forem destruídos (Levy, 1997). Minsky and Papert (1969) demonstraram que um único *Perceptron* somente resolve uma classe muito limitada de problemas que podem ser linearizados.

Neste relatório são apresentados os resultados do Trabalho 02 MLP de Previsão de Séries Temporais da disciplina ELE 2394, Redes Neurais I, da Engenharia elétrica.

## II. OBJETIVO E METODOLOGIA

As concessionárias de energia elétrica compram energia baseada na demanda futura. É notório que o clima (temperatura, precipitação, umidade relativa do ar, vento, etc) afeta o consumo de energia elétrica, principalmente o consumo de energia elétrica das classes residencial e comercial. A Light é uma concessionária caracterizada pelo consumo dessas duas classes. Esta característica fica evidente no caso de algumas

regiões da Light, onde o percentual de clientes residenciais e comerciais é maior do que 90%.

A Light está situada no estado do Rio de Janeiro, e por isso apresenta grandes diversidades climáticas dentro da sua área de concessão devido à proximidade do mar e à presença de montanhas. Portanto, estudar os efeitos do clima em relação à energia faturada e à carga é fundamental para aumentar a eficácia na previsão do volume de consumo e, consequentemente, o volume de compra de energia. Assim, uma das metas a serem atingidas pelas concessionárias é reduzir os erros nas estimativas da carga, reduzindo os prejuízos na compra de energia. Dessa forma, a empresa poderá reduzir o risco no fluxo de caixa permitindo futuros investimentos na expansão e qualidade dos serviços prestados a seus clientes.

Portanto, o objetivo deste trabalho é desenvolver um modelo para a previsão mensal da sensação térmica das diversas regiões ou unidades geográficas que fazem parte da área de concessão da Light.

A partir do modelo de previsão da sensação térmica se poderá desenvolver um modelo original de previsão de carga e faturamento da empresa, onde além de agregar a previsão da sensação térmica, também considerará dados históricos de carga e faturamento.

### Detalhamento

- Aplicação: Previsão mensal da Sensação Térmica em 8 regiões distintas do Município do Rio de Janeiro, parte da área de concessão da Light S.A.;
- Dados: Janeiro de 1998 a Dezembro de 2008;
- Modelo Neural: Treinamento de MLP com treinamento por Back Propagation;
- Saída da Rede: Previsão da demanda mensal 12 meses a frente (previsão multi-step);
- Treinamento e Validação: Valores entre Janeiro/1998 e Dezembro/2008;
- Teste: Janeiro a Dezembro de 2009;
- Software: MATLAB 2008b em diante.

Efetuar a previsão, 12 passos a frente, da sensação térmica mensal em uma das 8 regiões do Município do Rio de Janeiro (Centro, Zona Sul 1, Zona Sul 2, Zona Norte 1, Zona Norte 2, Oeste 1, Oeste 2, Oeste 3), variando os seguintes parâmetros de configuração e treinamento da Rede Neural.

### Testes

- Janela: Variar o tamanho da janela de entrada, tentando obter o melhor desempenho de generalização;
- Codificação do Mês: Variar o método de codificação da informação sobre o mês da previsão – uma entrada real, 12 entradas binárias (uma para cada mês) e 4 entradas binárias codificadas;

Professora: Marley. Eng. Elétrica. PUC-RIO

<sup>1</sup>Valor de entrada

- Topologia: Variar o número de processadores na camada escondida – escolher dois valores diferentes para cada configuração de janela de entrada; variar o tipo de função de ativação nas camadas escondida (logsig e tansig) e de saída (logsig e purelin);
- Treinamento: Utilizar o método de parada antecipada (early stop).

No final são apresentados os gráficos de treinamento e teste para cada configuração e o desempenho em termos das seguintes métricas:

- 1) MAPE (“Mean Absolute Percentage Error”);
- 2) RMSE (“Root Mean Square Error”).

O relatório apresenta uma tabela comparativa dessas duas métricas para todas as configurações de redes utilizadas. O relatório deve também conter uma discussão dos resultados encontrados em função dos parâmetros utilizados, tais como as diferentes codificações, os tamanhos da janela, os números de processadores e as condições de parada do treinamento com normalização dos dados de entrada.

### III. PRINCÍPIO TEÓRICO

O neurônio de McCulloch and Pitts (1943) propõe um limite binário para a criação de um modelo. Este neurônio artificial registra uma soma de pesos de  $n$  sinais de entrada,  $x_j$ ,  $j = 1, 2, 3, \dots, n$ , e fornece um *output*<sup>2</sup> de 1 caso esta soma esteja acima do limite  $u$ . Caso contrário o *output* é 0. Matematicamente essa relação pode ser descrita de acordo com a Eq. 1:

$$y = \theta \left( \sum_{j=1}^n w_j x_j - u \right) \quad (1)$$

Onde  $\theta$  é o passo dado na posição 0,  $w_j$  é chamada sinapse-peso associado a um *peso*  $j$ ésimo *input*. A título de simplificação a função limite<sup>3</sup>  $u$  é considerada um outro peso  $w_0 = -u$  anexado a um neurônio com um *input* constante  $x_0 = 1$ . Pesos positivos correspondem a uma sinapse **excitatória**, enquanto pesos negativos correspondem a uma sinapse **inibitória**. Este modelo contém uma série de simplificações que não refletem o verdadeiro comportamento dos neurônios biológicos (Mao, 1996).

Derivações do neurônio de McCulloch and Pitts (1943) na escolha das funções de ativação. Uma função largamente utilizada é a função sigmóide, que exibe uma suavização dos *outputs* a medida que o valor da função diminui (Mao, 1996; Misra and Saha, 2010). Essa função de ativação pode ser expressa de acordo com a Eq. 2:

$$g(x) = 1/(1 + e^{-\beta x}) \quad (2)$$

Onde  $\beta$  é o parâmetro de inclinação. A Fig. 1 ilustra a sequência lógica da operação de uma RNA para um neurônio simples de McCulloch-Pitts.

As redes alimentadas diretamente são aquelas redes cujos grafos orientados se distinguem pela presença de um ou mais camadas ocultas e cujos nós são chamados de neurônios ocultos. A função do neurônio é intervir entre a camada externa e a saída da rede de maneira útil. Adicionando-se camadas ocultas a rede torna-se capaz de realizar estatísticas de ordem elevada (Haykin, 1999).

### IV. RESULTADOS

A região escolhida para a realização deste trabalho foi a 1 localizada no centro do Rio de Janeiro. E o primeiro teste foi realizado uma mudança no tamanho da janela cuja primeira medida foi 6 e a segunda medida do janelamento foi 12.

### V. CONCLUSÕES

#### REFERÊNCIAS

- Feldman, J. A., Fanty, M. A., and Goddard, N. H. (1988). Computing With Structured Neural Networks. *Computer*, 21(3):91–103.
- Hagan, M. T., Demuth, H. B., Beale, M. H., and De Jesús, O. (1996). *Neural Network Design*. page 1012.
- Haykin, S. (1999). *Neural Networks: a comprehensive foundation*. Prentice Hall Inc., Porto Alegre, 2 edition.
- Kanal, L. N. (2001). Perceptrons. *Encyclopedia of Computer Science*, pages 11215–11218.
- Krogh, A. (2008). What are artificial neural networks? *Nature biotechnology*, 26(2):195–197.
- Levy, S. (1997). The Computer. *Newsweek*, 130(22):28.
- Mao, J. (1996). Why artificial neural networks? *Communications*, 29:31–44.
- McCulloch, W. S. and Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity. *The Bulletin of Mathematical Biophysics*, 5(4):115–133.
- Minsky, M. and Papert, S. (1969). *Perceptrons*. 2 edition.
- Misra, J. and Saha, I. (2010). Artificial neural networks in hardware: A survey of two decades of progress. *Neurocomputing*, 74(1-3):239–255.
- Nedjah, N., da Silva, F. P., de Sá, A. O., Mourelle, L. M., and Bonilla, D. A. (2016). A massively parallel pipelined reconfigurable design for M-PLN based neural networks for efficient image classification. *Neurocomputing*, 183:39–55.
- Poulton, M. M. (2002). Neural networks as an intelligence amplification tool: A review of applications. *Geophysics*, 67(3):979.
- Rosenblatt, F. (1962). Principles of Neurodynamics. Perceptrons and the Theory of Brain Mechanisms. *Archives of General Psychiatry*, 7:218–219.

<sup>2</sup>Valor de saída

<sup>3</sup>Genericamente chamada de função de ativação







Figura 1: Modelo esquemático de um neurônio de McCulloch-Pitts. Onde  $x_1, x_2, \dots, x_n$  são os *inputs*,  $w_1, w_2, \dots, w_n$  são os pesos,  $h$  é o treino,  $g(x)$  é a função de ativação, e  $y$  é o *output*.




(a) Treino




(a) Treino




(b) Teste



(b) Teste




(c) Validação




(c) Validação

Figura 2: Apresenta os teste realizados com o janelamento de 12.


Figura 3: Apresenta os teste realizados com o janelamento de 12.




(a) Treino




(b) Teste




(c) Validação



(a) Treino




(b) Teste




(c) Validação

Figura 4: Apresenta os teste realizados com o janelamento de 12.


Figura 5: Apresenta os teste realizados com o janelamento de 12.




(a) Treino




(b) Teste




(c) Validação



(a) Treino




(b) Teste




(c) Validação

Figura 6: Apresenta os teste realizados com o janelamento de 12.


Figura 7: Apresenta os teste realizados com o janelamento de 12.




(a) Treino




(b) Teste




(c) Validação



(a) Treino



(b) Teste



(c) Validação

Figura 8: Apresenta os teste realizados com o janelamento de 12.

Figura 9: Apresenta os teste realizados com o janelamento de 12.