

Relatório sobre o Mapa de Kohonen

Victor Carreira

Resumo—

I. INTRODUÇÃO

As Redes Neurais Artificiais (RNA) são inspiradas em modelos sensoriais do processamento de tarefas realizadas pelo cérebro (Hagan et al., 1996). Uma RNA, portanto pode ser criada através da aplicação de algoritmos matemáticos que imitem a tarefa realizada por um neurônio (Nedjah et al., 2016). Uma rede neural artificial possui semelhanças com a rede biológica presente no sistema nervoso central, neste o cômputo de informações realizado do cérebro é feito através de uma vasta quantidade de neurônios interconectados (Feldman et al., 1988; Poulton, 2002). A comunicação entre essas células é realizada através de impulsos elétricos. Estes são transmitidos e recebidos por meio de sinapses nervosas entre axônios e dendritos. As sinapses são estruturas elementares e uma unidade funcional localizada entre dois neurônios (Krogh, 2008).

McCulloch and Pitts (1943) redigem o trabalho pioneiro onde foi modelado um neurônio cuja resposta dependia do *input*¹ que provinha de outros neurônios e do peso utilizado. Já Rosenblatt (1962) cria a teoria de convergência do *Perceptron* onde ele prova que modelos de neurônios possuem propriedades similares ao cérebro humano (Kanal, 2001). Neste sentido as rede neuronais artificiais podem realizar performances sofisticadas no reconhecimento de padrões, mesmo se alguns neurônios forem destruídos (Levy, 1997). Minsky and Papert (1969) demonstraram que um único *Perceptron* somente resolve uma classe muito limitada de problemas que podem ser linearizados.

Neste relatório são apresentados os resultados do Trabalho 03 mapas de Kohonen da disciplina ELE 2394, Redes Neurais I, da Engenharia elétrica.

II. OBJETIVO E METODOLOGIA

Em um hospital na Austrália, 215 pacientes foram submetidos a 5 testes de laboratórios. Testes adicionais, como por exemplo o exame clínico, permitiram determinar se os pacientes tinham eutiroidismo (normal), hipotireoidismo ou hipertireoidismo. Os resultados dos 5 testes e a condição da tireóide de cada paciente estão na base de dados new-thyroid.dat cujas colunas representam:

- 1) Percentual da resina-T3.
- 2) Tiroxina total.
- 3) Triiodotironina total.
- 4) Hormônio estimulador da tireóide (TSH)

- 5) Diferença absoluta máxima no valor da TSH após a injeção de 200 micro gramas de hormônio de liberação de tirotropina.
- 6) Classe (1 = normal, 2 = hyper, 3 = hypo).

O objetivo é, utilizando mapas de Kohonen, agrupar os diferentes tipos de pacientes e em seguida determinar o perfil de cada grupo obtido. Sendo assim, o trabalho está dividido em duas partes: configuração do mapa e análise dos resultados.

Configuração do mapa:

- a Topologia
- b Tipo de Normalização dos dados de entrada
- c Tempo de treinamento durante a fase de ordenação
- d Tempo de treinamento durante a fase de ajuste fino

Para os parâmetros que não listados, deve-se escolher um valor e explicar a escolha. Analise os resultados obtidos e determine a melhor configuração obtida.

Análise dos resultados:

- e Utilizando a melhor configuração do item 1, analise os diferentes mapas fornecidos.
- f Caracterize os grupos de pacientes obtidos.

III. PRINCÍPIO TEÓRICO

O neurônio de McCulloch and Pitts (1943) propõe um limite binário para a criação de um modelo. Este neurônio artificial registra uma soma de pesos de n sinais de entrada, x_j , $j = 1, 2, 3, \dots, n$, e fornece um *output*² de 1 caso esta soma esteja acima do limite u . Caso contrário o *output* é 0. Matematicamente essa relação pode ser descrita de acordo com a Eq. 1:

$$y = \theta \left(\sum_{j=1}^n w_j x_j - u \right) \quad (1)$$

Onde θ é o passo dado na posição 0, w_j é chamada sinapse-peso associado a um *jésimo input*. A título de simplificação a função limite³ u é considerada um outro peso $w_0 = -u$ anexado a um neurônio com um *input* constante $x_0 = 1$. Pesos positivos correspondem a uma sinapse **excitatória**, enquanto pesos negativos correspondem a uma sinapse **inibitória**. Este modelo contém uma série de simplificações que não refletem o verdadeiro comportamento dos neurônios biológicos (Mao, 1996).

Derivações do neurônio de McCulloch and Pitts (1943) na escolha das funções de ativação. Uma função largamente utilizada é a função sigmóide, que exhibe uma suavização dos *outputs* a medida que o valor da função diminui (Mao, 1996;

Professora: Marley. Eng. Elétrica. PUC-RIO

¹Valor de entrada

²Valor de saída

³Genericamente chamada de função de ativação

Misra and Saha, 2010). Essa função de ativação pode ser expressa de acordo com a Eq. 2:

$$g(x) = 1/(1 + e^{-\beta x}) \quad (2)$$

Onde β é o parâmetro de inclinação.

IV. RESULTADOS

V. CONCLUSÕES

REFERÊNCIAS

- Feldman, J. A., Fanty, M. A., and Goddard, N. H. (1988). Computing With Structured Neural Networks. *Computer*, 21(3):91–103.
- Hagan, M. T., Demuth, H. B., Beale, M. H., and De Jesús, O. (1996). *Neural Network Design*. page 1012.
- Haykin, S. (1999). *Neural Networks: a comprehensive foundation*. Prentice Hall Inc., Porto Alegre, 2 edition.
- Kanal, L. N. (2001). Perceptrons. *Encyclopedia of Computer Science*, pages 11215–11218.
- Krogh, A. (2008). What are artificial neural networks? *Nature biotechnology*, 26(2):195–197.
- Levy, S. (1997). The Computer. *Newsweek*, 130(22):28.
- Mao, J. (1996). Why artificial neural networks? *Communications*, 29:31–44.
- McCulloch, W. S. and Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity. *The Bulletin of Mathematical Biophysics*, 5(4):115–133.
- Minsky, M. and Papert, S. (1969). *Perceptrons*. 2 edition.
- Misra, J. and Saha, I. (2010). Artificial neural networks in hardware: A survey of two decades of progress. *Neurocomputing*, 74(1-3):239–255.
- Nedjah, N., da Silva, F. P., de Sá, A. O., Mourelle, L. M., and Bonilla, D. A. (2016). A massively parallel pipelined reconfigurable design for M-PLN based neural networks for efficient image classification. *Neurocomputing*, 183:39–55.
- Poulton, M. M. (2002). Neural networks as an intelligence amplification tool: A review of applications. *Geophysics*, 67(3):979.
- Rosenblatt, F. (1962). Principles of Neurodynamics. Perceptrons and the Theory of Brain Mechanisms. *Archives of General Psychiatry*, 7:218–219.